



Laboratory #2

ML Supervised Classification Learning

Contents	
Redovisning	1
Inlämning	2
DEADLINE	2
u1. k-NN algoritmen [ScreenRec]	2
u2. Decision Trees [ScreenRec]	3
Bilaga 1. Hur söka efter data set?	4

Jobba i **parvis**. För att kunna lämna in **måste Du tillhöra en Canvas-grupp**. Även om Du är ensam måste du finnas i en Canvasgrupp.

Inlämning

I inlämningen i Canvas måste detta finnas med:

1. Källfiler med data
2. En *välkommenterad* Jupyter Notebook **per uppgift u1** till **u2** (*.ipynb - filer)
 - a. Koden måste vara körbar direkt! Tänk på därför på sökvägar.
3. Ett filmklipp **per uppgift** (länkar eller videofiler).

Redovisning

Parvis jobb = Redovisa en uppgift var. Enskilt jobb = redovisa båda uppgifterna.

Muntlig redovisning under **max 10 minuter per uppgift** som är markerad med **[ScreenRec]**. Du redovisar genom att använda en sk screen recorder (streaming skärminspelare). Ange länk till Din produktion i lärplattformen.

- Skicka in både dataset och kod (som ipynb-fil)
- Välj en streaming screen recorder t ex Open Broadcaster Software (OBS) <https://obsproject.com/> eller annan. Bakgrundsljud, som t ex musik, får ej förekomma. Du väljer själv om du vill skapa en fil som du skickar in, länkar till

eller om du vill publicera på Youtube. Ange länken i lärplattformen på sidan för inlämning.

- Visa och förklara genom demonstration. Beskriv hur Du löste problemen medan du exekverar och demonstrerar Din applikation (Du redovisar alltså hemma genom att spela in/filma Din skärm (inte statiska bilder dvs skärmdumpar), där Du kan visa med muspekare, skriva kod och givetvis tala in ljud.
- **Sist i videoklippet redogör för er egen reflektion över UPPGIFTEN.** Vad du tyckte om den, vad var intressant, vad du lärt dig, vad du skulle vilja lära dig mer av, mm mm.

DEADLINE

Enligt Canvasplattformen.

Start - Gäller alla uppgifter

Välj ett eget dataset

Uppgifterna löses i Python i Jupyter Notes. Använd **ett av Dig valt dataset** här:

<https://archive.ics.uci.edu/datasets?Task=Classification&FeatureTypes=Numerical&skip=0&take=10&sort=desc&orderBy=NumHits&search=&Types=Multivariate&NumFeatures=3&NumFeatures=40>

- Antalet **features** (attribut) måste **minst tre** och av typen **numeric**
- **Target variable** (dependent variable) måste ha **minst tre** klasser/kategorier. Ex: Om target variable är Colour så måste minst tre färger klassificeras t ex blå, grön och röd.
- **#Instances** (som är antalet observationer = rader) bör ofta vara mer än 50 per targetklass
- OBS! Dessa dataset får **EJ användas**: “Glass Identification Database”, “Seeds”, “Haberman's Survival”, “Yeast”, “Wholesale customers Data Set”, “Wireless Indoor Localization Data Set” eller “iris”.
- **Max tre (3) grupper per valt dataset. Skriv ned ditt valda dataset** i denna fil https://docs.google.com/spreadsheets/d/1d1E4xMVOI4_y4ntpA1O27Yrbun9CrUWyxuKpLRGfowy/edit?usp=sharing

Se även *Bilaga 1. Hur söka efter dataset?*

u1. k-NN algoritmen [\[ScreenRec\]](#)

Mål: Visa att du förstått klassificeringsalgoritmen kNN genom att demonstrera kod och exekvering.

INNAN du startar: Gå igenom kNN exemplet med Iris-datasetet från föreläsningen, ordentligt.



Förklara och demonstrera nedanstående (uppg. a,b,c) **på svenska** under **max 10 minuter** i en **screen recording**:

För varje körning nedan, presentera confusion matrix och värdet på Accuracy

Variera k genom att i tre olika exekveringar, **välja** olika udda heltal på k (i intervallet 3 t.o.m 15). Du kan välja fler

- Redogör för vilken skillnad blir det blir med olika k
- Prova två körningar och redogör för vilken skillnad blir det i de två fallen:
 - med icke-normaliserat data, dvs originaldata.
 - med normaliserat data i intervallet $[0,1]$

■ Tips för normalisering:

<https://machinelearningmastery.com/standardscaler-and-minmax-scaler-transforms-in-python/>

- I dessa körningar förändra antalet tränings- och testfall, så att:
 - train=75%, test=25%
 - train= $\frac{2}{3}$, test= $\frac{1}{3}$
 - train=50%, test=50%

Sammanlagt blir det här $3 * 2 * 3 = 18$ körningar (Varför? Eftersom det dels var tre olika k , dels skulle data skulle vara i originalform resp. normaliserat och dels skulle tränings-/testdatamängder varieras på tre sätt.), se Fig 1.




Fig. 1 Översikt på antal körningar

Presentera de tre bästa exekveringarna, med avseende på prestandan (t ex värdet på Accuracy) hos klassificeringsalgoritmen. Visa alltid confusion matrix och accuracy för varje redogjord körning.

u2. Decision Trees [\[ScreenRec\]](#)

Mål: Visa att du förstått hur klassificering kan göras med hjälp av decision trees (beslutsträd) genom att använda DecisionTreeClassifier.

INNAN du startar: Gå igenom decision tree exemplet med Iris-datasetet från föreläsningen, ordentligt. Se exempelkod från föreläsning.

Förklara och demonstrera nedanstående (uppg. a,b) under **på svenska under max 10 minuter** i en **screen recording**:

För varje körning nedan, presentera confusion matrix och värdet på Accuracy

- a. Prova två körningar och redogör för vilken skillnad blir det i de två fallen:
 - i. med icke-normaliserat data, dvs originaldata.
 - ii. med normaliserat data i intervallet [0,1]
 - Tips för normalisering:
<https://machinelearningmastery.com/standardscaler-and-minmax-scaler-transforms-in-python/>
- b. I dessa körningar förändra antalet tränings- och testfall. Sätt `random_state=None` i `DecisionTreeClassifier` konstruktorn (innebär att test och träningsobservationerna verkligen slumpas varje gång du kör) och kör varje punkt nedan 100 gånger (allt från början till slut) och beräkna *medelvärdet på prestandan* av dessa 100 körningar:
 - i. `train=75%`, `test=25%`
 - ii. välj själv ett förhållande mellan träning och test

Presentera en av de bästa exekveringarna, med avseende på prestandan (värdet på Accuracy) hos klassificeringsalgoritmen. Visa alltid confusion matrix och accuracy.



DALARNA
UNIVERSITY

Artificial Intelligence, GIK2FB

Bilaga 1. Hur söka efter data set?

Att söka efter lämpligt dataset för klassificering (Classification, Numerical, Multivariate). Sortera gärna på #attribute (som ju är Features) och prova ett dataset med **mer än 3 attribut**, UNDIK time series data som innehåller sekventiellt data:
<https://archive.ics.uci.edu/datasets?Task=Classification&FeatureTypes=Numerical&skip=0&take=10&sort=desc&orderBy=NumHits&search=&Types=Multivariate&NumFeatures=3&NumFeatures=40>

Kolla att **Target variable** (dependent variable) har **minst tre** klasser/kategorier. Ex: Om target variable är Colour så måste minst tre färger klassificeras t ex blå, grön och röd.

En del förslag: