



Data Science & Machine Learning: 7,5hp
Laboratory #1 – Statistical Inference and Data
Analytics

10 April 2025

Innehåll

I	Formalia	3
1	Förutsättning	3
2	Mål/syfte	3
3	Hjälpmedel	3
3.1	Verktyg	3
4	Deadline	3
5	Arbetsformer	3
6	Redovisning	4
7	Betygsgränser	5
II	Uppgifter	6
8	Warming up in Python	6
9	One Sample t-test: Compare the mean of a single sample with a known population mean	6
10	The One Sample t-test	7
11	The Two-sample Independent t-test	8
12	Paired t-test	8

Del I

Formalia

1 Förutsättning

2 Mål/syfte

Labben är mer av lärande än prövande karaktär. Målet med denna laboration är att Du ska:

1. introduceras i statistisk miljö i Python 3 och använda språket som en hjälp i Dina statistiska beräkningar.
2. uppöva färdigheter i att utföra hypotestestning med olika typer av t-test som en del av forskningsstrategierna experiment och observation.

3 Hjälpmedel

Allt, men **se upp för plagiering**. Plagiering är i korthet *att lämna in någon annans arbete som sitt eget* (detta inkluderar människa och maskin). Detta kan i många fall ske omedvetet och det är därför Du måste läsa anvisningen under rubriken Redovisning.

3.1 Verktyg

Jupyter Notebook i **Anaconda** används i denna labb.

4 Deadline

Se denna laborationsmapps öppettider under Inlämningsmappen i lärplattformen, som innehöll denna fil.

5 Arbetsformer

Uppgifterna löses genom att i **första hand** jobba i **grupp om tre eller parvis** eller i tredje hand individuellt. Ej fler än tre personer per lösning. Redovisning sker enligt 6.

6 Redovisning

Se upp för plagiat

Plagiering är i korthet *att lämna in någon annans arbete som sitt eget*. Detta kan i många fall ske omedvetet och det är därför som Du uppmanas läsa nedanstående.

Genom Din aktiva handling att skicka in denna examinerande uppgift, så bekräftar/intygar Du att Du har läst, förstått och följt följande instruktioner **OM PLAGIERING OCH PLAGIERINGSVERKTYG** innefattande allt innehåll i länkarna på den sidan och i synnerhet länken "Refero" längst ned på sidan.

- **HUR ska man göra? Läs under SKRIVA OCH REFERERA**

1. Lös **alla** uppgifter. **Redovisning sker gruppvis** och **alla personer i gruppen måste presentera**. Du kan också jobba själv. VIKTIGT: Se till att Du förstår.
2. Lös alla uppgifter, Redovisa muntligt under max 6 minuter per uppgift. Du redovisar genom att använda en sk screen recorder (streaming skärminspelare), utan bakgrundsljud. Ange länken till Din produktion vid inlämningen lärplattformen.
— **Vem redovisar vad?** Använd Python och skriv ett kort program som slumpar ut vem som ska redovisa vilken uppgift. Använd `random.seed(2025)`. Lägg in Era efternamn som strängar i en lista. Sortera listan i stigande ordning. Slumpa ut namnen från 0 till 2 och skriv ut ordning. (Om ni är tre så redovisar bi en uppgift var, om ni är två så redovisar en av er två uppgifter och den andre en och om du är själv så redovisar du alla uppgifter)
 - (a) slumpad siffra/index 0 ska Du redovisa uppgift 10
 - (b) Slumpad siffra/index 1 ska Du redovisa uppgift 11
 - (c) Slumpad siffra/index 2 ska Du redovisa uppgift 12
 - Välj en streaming screen recorder t ex Open Broadcaster Software (OBS) <https://obsproject.com/> eller annan. Du väljer själv om du vill skapa en fil som du länkar till eller om du vill publicera på t ex Youtube. Efter att presentationen har rättats kan Du ta bort den permanent. Ange länken i lärplattformen.
 - (a) **På svenska, visa och förklara genom demonstration.** Beskriv hur Du löste problemen medan du exekverar och demonstrerar Din applikation (Du redovisar alltså genom att spela in/"filma" Din skärm (inte statiska bilder dvs skärmdumpar), där Du kan visa med muspekare, skriva kod om givetvis tala in ljud.)
 - (b) Sist i videoklipppet ska ni (du) **redovisa er (din) egen reflektion** på denna labb. Vad du tyckte om den, vad var intressant, vad du lärt dig, vad du skulle vilja lära dig mer av, mm mm

3. I **Canvas** skickar du in: 1. videoklipp (er demo) eller länk till den, och 2. källkoden som du demonstrerat i form av en `*.ipynb` fil, och 3) Redovisa i text vem du jobbat med.

7 Betygsgränser

För betyget:

Betyg G ska *alla* uppgifter/deluppgifter vara komplett lösta, *exklusive* [***Extra***].
[Booleskt beslut. Endera är allt löst eller inte] Dokumentation måste finnas med, se nedan.

Betyg U Kriterier för G är inte uppfyllda. [Booleskt beslut. Endera är allt löst eller inte] Dokumentation måste finnas med, se nedan.

Uppgifterna ska alltså vara komplett lösta på den nivå som anges ovan. Inga delpoäng ges.

Del II

Uppgifter

8 Warming up in Python

1. Enter these values and assign them to a data structure: 63, 71, 41, 92, 11, 85, 79, 21, 54, 7, 1, 34.
Create a **Python function** called *mySummary* to display the summary statistics from a to j, below:
 - (a) number of samples, i.e the length of the data structure e.g in a list
 - (b) median value
 - (c) mean value
 - (d) max value
 - (e) min value
 - (f) standard deviation
 - (g) inter-quartile range
 - (h) Sort the numbers in ascending and descending order, respectively
 - (i) plot the values as a *histogram*
 - (j) plot the values as a *bar plot*

9 One Sample t-test: Compare the mean of a single sample with a known population mean

1. Watch this movie clip: [One Sample t-Test](#) [4 min], in where a one sample t-test is computed manually using look-up tables and so on.
 - (a) Notes: In the video, the significance level is 5%, i.e. $\alpha = 0.05$. The degrees of freedom (*df*) is 29, which is the number of samples minus 1 (You don't have to think about the *df* when using Python!). The *test statistic* (shown after 3min:30sec in the video) i.e. the t-value is computed by a built-in function in Python.
2. When searching for tests you will often find the z-test, as well as the t-test. What is the basic difference in between a z-test and a t-test?
3. By using Python, repeat the same *One-sample t-test* as shown in the video. Note: You do should not use a t-distribution look-up table as in the video. Instead, an exact p-value will be computed for you in Python! Compare the results! They should be just about the same as in the video ... :)

- Use this dataset for the analysis: 125.2994, 126.4402, 171.2639, 143.5338, 160.2288, 97.2396, 132.6253, 125.3658, 157.1991, 155.7616, 130.6605, 149.1697, 134.3806, 138.2204, 146.3384, 117.8715, 152.3988, 172.9519, 159.7141, 132.7292, 137.4430, 190.0342, 116.9569, 134.5817, 149.3947, 130.4849, 124.4223, 127.3084, 108.9376, 151.0511
 - Explore and present the data by displaying summary statistics and plots
4. In your own words, explain what the null hypothesis H_0 and the alternative hypothesis, H_a , are, **and** (based on the results) motivate whether H_0 should be rejected or not. Explain your thoughts based on the result.

10 The One Sample t-test

[The One Sample t-test compares the mean of a single sample with a stated population mean]

A random sample of 30 seventh grade pupils marks have been collected, in where marks range from 1 (worst) to 6 (excellent). The mean grade of **all** seventh grade pupils of the last five years was 4.2.

Is the mean of the sample of 30 pupils statistically different from the population mean?

1. Formulate your *null hypothesis* (H_0) and its alternative hypothesis (H_a) based on the problem above. Hint: H_0 : ... is equal to ..., and H_a : ... is not equal to ...
2. Read Reading and Writing CSV Files in Python Note: There are different ways of reading and writing! Choose your way.
3. Use this data by reading the file (in Canvas):
`courseresults3.csv`
4. Of what kind of *data type* is `gradeData`? Use the command: `type(gradeData)`.
5. Explore data by displaying summary statistics and plots
6. What is the standard deviation for the sample?
7. What is the sample mean?
8. What is the median?
9. Compute a *one sample t-test* for the sample using the known stated population mean, $\mu = 4.2$, at 5% significance level, i.e. $\alpha = 0.05$
10. What is the t-value?
11. What is the p-value?
12. What is the confidence interval?
13. Motivate whether H_0 should be rejected or not. Explain your thoughts based on the result.

11 The Two-sample Independent t-test

[The Two-Sample Independent t-test compares the difference between the means in two unrelated groups]

You have installed a heavy CPU demanding application on a new server. The same application also resides on an older server. You would like to test if there is a *difference between the application execution time* on the new server and the old server.

You execute the application several times on the new server and on the old server. You measure the execution time (sec) and the output is tab separated text-file.

1. Formulate your *null hypothesis* (H_0) and its alternative hypothesis (H_a) based on the problem above. Hint: H_0 : ... equal to ..., and H_a : ... is not equal to ...
2. Read Reading and Writing CSV Files in Python Note: There are different ways of reading and writing! Choose your way.
3. Apply this by reading the data file:
 - server2.txt
4. Using the command: `type(execTime)`. Of what *data type* is `execTime`?
5. Explore data by displaying summary statistics and plots
6. Compute a *two sample independent t-test* for the two samples at 5% significance level, i.e. $\alpha = 0.05$
7. What is the t-value?
8. What is the p-value?
9. What is the mean of the two samples, respectively?
10. What is the confidence interval?
11. Motivate whether H_0 should be rejected or not. Explain your thoughts based on the result.

12 Paired t-test

A random sample of 20 students were collected. During the test, two measurements (i.e test results) of each person were taken, one **before** and one **after** a set of teaching sessions.

1. What is the "treatment" in this case?
2. Formulate your *null hypothesis* (H_0) and its alternative hypothesis (H_a) based on the problem.

3. Read the file `diagnosticTest.csv`. There are three columns; The student number, test result before teaching, test result after teaching. Each row represent the same subject measurements before and after.
4. Explore data by displaying summary statistics and plots
 - (a) Present summary statistics for the two groups (i.e. the before and after measures, respectively)
 - (b) Display the confidence intervals, one for each
 - (c) Display the data groups *before* and *after* as boxplots
5. Compute a *two sample dependent t-test* (i.e. a paired t-test) for the two samples at 5% significance level, i.e. $\alpha = 0.05$ (Unsure what method to use? try `scipy.stats.ttest_rel()`)
6. What is the t-value?
7. What is the p-value?
8. Motivate whether H_0 should be rejected or not. Explain your thoughts based on the result

References