

Data Science & Machine Learning: 7,5hp
Laboratory #2 – More Statistical Inference and
Data Analytics

17 April 2025

Innehåll

I	Formalia	3
1	Förutsättning	3
2	Mål/syfte	3
3	Hjälpmedel	3
3.1	Verktyg	3
4	Deadline	3
5	Arbetsformer	3
6	Redovisning	4
7	Betygsgränser	5
II	Uppgifter	6
8	One-way ANOVA, or Kruskal-Wallis Test	6
9	Chi-Square (χ^2) Goodness-of-Fit test	7
10	Chi-Square (χ^2) Test of Independence	7

Del I

Formalia

1 Förutsättning

2 Mål/syfte

Labben är mer av lärande än prövande karaktär. Målet med denna laboration är att Du ska:

1. introduceras i statistisk miljö i Python 3 och använda språket som en hjälp i Dina statistiska beräkningar.
2. uppöva färdigheter i att utföra hypotestestning med olika typer av t-test som en del av forskningsstrategierna experiment och observation.

3 Hjälpmedel

Allt, men **se upp för plagiering**. Plagiering är i korthet *att lämna in någon annans arbete som sitt eget* (detta inkluderar människa och maskin). Detta kan i många fall ske omedvetet och det är därför Du måste läsa anvisningen under rubriken Redovisning.

3.1 Verktyg

Jupyter Notebook i **Anaconda** används i denna labb.

4 Deadline

Se denna laborationsmapps öppettider under Inlämningsmappen i lärplattformen, som innehöll denna fil.

5 Arbetsformer

Uppgifterna löses genom att i **första hand** jobba **i grupp om tre, parvis** eller i tredje hand individuellt. Ej fler än tre personer per lösning. Redovisning sker enligt 6.

6 Redovisning

Se upp för plagiat

Plagiering är i korthet *att lämna in någon annans arbete som sitt eget*. Detta kan i många fall ske omedvetet och det är därför som Du uppmanas läsa nedanstående.

Genom Din aktiva handling att skicka in denna examinerande uppgift, så bekräftar/intygar Du att Du har läst, förstått och följt följande instruktioner **OM PLAGIERING OCH PLAGIERINGSVERKTYG** innefattande allt innehåll i länkarna på den sidan och i synnerhet länken "Refero" längst ned på sidan.

- **HUR ska man göra? Läs under SKRIVA OCH REFERERA**

1. Lös alla uppgifter. **Redovisning sker gruppvis** och **alla personer i gruppen måste presentera**. Du kan också jobba själv. VIKTIGT: Se till att Du förstår.
2. Lös alla uppgifter, Redovisa muntligt under max 5 minuter per uppgift. Du redovisar genom att använda en sk screen recorder (streaming skärminspelare), utan bakgrundsljud. Ange länken till Din produktion vid inlämningen lärplattformen. Vilken uppgift ska redovisas muntligt?
— **Vem redovisar vad?** Använd Python. Skapa ett kort program. Använda `random.seed(2024)`. Lägg in Era efternamn som strängar i en lista. Sortera listan i stigande ordning Slumpa ut tre element från 0 till 2 och skriv ut ordning.
 - (a) slumpad siffra/index 0 ska Du redovisa uppgift 8
 - (b) Slumpad siffra/index 1 ska Du redovisa uppgift 9
 - (c) Slumpad siffra/index 2 ska Du redovisa uppgift 10
 - Välj en streaming screen recorder t ex Open Broadcaster Software (OBS) <https://obsproject.com/> eller annan. Du väljer själv om du vill skapa en fil som du länkar till eller om du vill publicera på t ex Youtube. Efter att presentationen har rättats kan Du ta bort den permanent. Ange länken i lärplattformen.
 - (a) **På svenska, visa och förklara genom demonstration.** Beskriv hur Du löste problemen medan du exekverar och demonstrerar Din applikation (Du redovisar alltså genom att spela in/"filma" Din skärm (inte statiska bilder dvs skärmdumpar), där Du kan visa med muspekare, skriva kod om givetvis tala in ljud.)
 - (b) Sist i videoklipppet ska ni (du) **redovisa er (din) egen reflektion** på denna labb. Vad du tyckte om den, vad var intressant, vad du lärt dig, vad du skulle vilja lära dig mer av, mm mm
3. I **Canvas** skickar du in: 1. videoklipp (er demo) eller länk till den, och 2. källkoden som du demonstrerat i form av en *.ipynb fil, och 3) Redovisa i text vem du jobbat med.

7 Betygsgränser

För betyget:

Betyg G ska *alla* uppgifter/deluppgifter vara komplett lösta, *exklusive* [***Extra***].
[Booleskt beslut. Endera är allt löst eller inte] Dokumentation måste finnas med, se nedan.

Betyg U Kriterier för G är inte uppfyllda. [Booleskt beslut. Endera är allt löst eller inte] Dokumentation måste finnas med, se nedan.

Uppgifterna ska alltså vara komplett lösta på den nivå som anges ovan. Inga delpoäng ges.

Del II

Uppgifter

8 One-way ANOVA, or Kruskal-Wallis Test

One-way **A**nalysis of **V**ariance (ANOVA) is used when comparing three or more groups of data on the interval/ratio scale.

Assignment: We have three groups with seven observations per group, as follows: **webcount.csv**

The file contains the number of visits (by the thousands) per week on three national websites (located in Sweden, Finland, and Norway). The websites are owned by the same company. The websites have a similar content (essentially only the written language differs), but the target audience are located in the three different countries. The manager team wants to know if the number of website visits are equal between the three websites, or not. Perform a Oneway ANOVA test and find out!

1. Formulate your *null hypothesis* (H_0) and its alternative hypothesis (H_a) based on the problem.
2. Read the file. There are three columns; a website in Sweden, website in Finland, website in Norway. Each row represent the number of website visits per week (by the thousands).
3. Present summary statistics for the three groups
4. Display confidence intervals for the three groups, one for each.
5. Display the three groups as boxplots
6. Provide arguments for stating that your data samples are normal or not. Support your arguments with:
 - (a) qualitative assessment on the box plots above (or additional histograms)
 - (b) qualitative assessment by using QQ plots
 - (c) quantitative assessment by using the Shapiro-Wilks Test.
7. Check for outliers and display the result(s). State your conclusion for presence or non-presence of outliers and your actions taken.
8. based on your conclusions about the normality of data either carry a Oneway ANOVA test, or a Kruskal-Wallis Test
9. Motivate whether H_0 should be rejected or not. Explain your thoughts based on the result
10. If H_0 was rejected, perform a post-hoc test namely the Tukeys HSD test to see which group(s) are different. Explain your thoughts.

9 Chi-Square (χ^2) Goodness-of-Fit test

Chi-Square (χ^2) Goodness-of-Fit test is a **non-parametric test** that is used to find out how the observed value of a given phenomena is significantly different from the expected value. In Chi-Square goodness of fit test, the term **Goodness-of-Fit** is used to compare the observed sample distribution with the expected probability distribution.

Chi-Square goodness of fit test determines how well theoretical distribution (such as normal, uniform, binomial, or Poisson) fits the empirical distribution. In Chi-Square goodness of fit test, sample data is divided into intervals. Then the numbers of points that fall into the interval are compared, with the expected numbers of points in each interval.

Assignment: The People Code, created by Dr. Taylor Hartman, divides personalities into four colors: Red (motivated by power), Blue (motivated by intimacy), White (motivated by peace), and Yellow (motivated by fun). Although different groups of people have different demographics, the general breakdown suggests that Reds comprise 25% of the population; Blues 35%; Whites 20%; and Yellows 20%. Respondents were to answer a 45-question test which assesses one's color, based on whether you answer A, B, C, or D. After analysing the test results, the **390** respondents were assigned the classes as in Table 1.

Red	Blue	White	Yellow	SUM
122	128	70	80	390

Tabell 1: The test results

Can we conclude your collected sample represents the distribution of the population? That is, how "good" do the data "fit" the expected probability model?

1. Formulate your *null hypothesis* (H_0) and its alternative hypothesis (H_a) based on the problem above.
2. Which are the **observed values**?
3. Which are the **expected values** and **expected relative frequency** i.e. the **expected probability distribution**?
4. Motivate whether H_0 should be rejected or not. Explain your thoughts based on the result.
5. Explain in plain words what your result means!

10 Chi-Square (χ^2) Test of Independence

A National University Board believes that, there will be a pattern of difference such that there will be more people whose university decision was affected by university

sports AND who watched sports. The hypothesis suggests that we expect to see a correlation between individuals who regularly watch sports those who choose their university studies having sports as a part of the education.

Here are frequencies of watching sports and how much university sports teams affect the choice of university attendance.

	Primary Affect Decision	Somewhat Affect Decision	Did not Affect Decision	Total
Watched sports	47	26	14	87
Did not watch sports	21	23	37	81
Total	68	49	51	168

Tabell 2: Observed frequencies

1. Formulate your *null hypothesis* (H_0) and its alternative hypothesis (H_a) based on the problem.
2. What are the **expected values** and **expected relative frequency** i.e. the **expected probability distribution**? (Show it as the table of observed frequencies)
3. Motivate whether H_0 should be rejected or not. Explain your thoughts based on the result.
4. Explain in plain words what your result means!

References