

1. Introduktion till statistisk analys

Centraltendens viktigaste mått

Typvärde: värde som är oftast förekommande

Median: Värdet i mitten

Medelvärde: Total/antal variabler

T.ex. 3, 5, 4, 3, 3, 6, 11

Typvärde: 3

Median: 3, 3, 3, 4, 5, 6, 11 -> 4

Medelvärde: $3 + 5 + 4 + 3 + 3 + 6 + 11 = 35 / 7 = 5$

Beskrivande Statistik

1. Definition : Beskrivande statistik sammanfattar och beskriver egenskaperna hos en dataset.

2. Mått på central tendens :

- Medelvärde (Average) : Summan av alla värden delat med antalet värden.
- Median : Det mittersta värdet i en sorterad lista av värden.
- Typvärde (Mode) : Det mest frekventa värdet i datasetet.

3. Mått på spridning:

- Standardavvikelse (Standard Deviation) : Mått på hur mycket värdena varierar från medelvärdet.
- Varians: Kvadraten på standardavvikelsen.
- Interkvartilavstånd (IQR): Skillnaden mellan den första och tredje kvartilen (Q3 - Q1).
- Range: Skillnaden mellan det största och minsta värdet.

4. Visuella representationer:

- Histogram: Visar fördelningen av datasetet.
- Boxplot: Visar spridningen och identifierar potentiella outliers.
- Stapeldiagram: Används för kategoriska data.
- Cirkeldiagram : Används för att visa proportioner av en helhet.

Syfte : Ge en övergripande bild av datasetet för att identifiera mönster, trender och avvikelser.

Analytisk Statistik

1. Definition : Analytisk statistik, även känd som inferential statistik, används för att dra slutsatser om en population baserat på ett urval.

2. Hypotesprövning :

- Nollhypotes (H_0) : Antagandet att det inte finns någon effekt eller skillnad.
- Alternativ hypotes (H_1) : Antagandet att det finns en effekt eller skillnad.
- p-värde : Sannolikheten att få ett resultat minst lika extremt som det observerade, under antagandet att nollhypotesen är sann.

3. Konfidensintervall : Ett intervall av värden som troligtvis innehåller den sanna populationsparametern.

4. Statistiska tester :

- t-test : Används för att jämföra medelvärden mellan två grupper.
- ANOVA (Analys av varians) : Används för att jämföra medelvärden mellan tre eller fler grupper.
- Chi2-test : Används för att undersöka samband mellan två kategoriska variabler.
- Regressionsanalys : Används för att modellera relationen mellan en beroende variabel och en eller flera oberoende variabler.

5. Sampling :

- Slumpmässigt urval : Varje medlem i populationen har lika stor chans att bli vald.
- Stratifierat urval : Populationen delas in i strata och slumpmässiga urval tas från varje strata.

Syfte : Dra slutsatser och göra förutsägelser om en population, baserat på analysen av urvalet från populationen.

Dessa två områden inom statistik kompletterar varandra och används ofta i kombination för att få en fullständig bild av data och dra informerade slutsatser.

Variabeltyper

Kvantitet: Variabelvärdet är svaret på hur många

Kvalitativ: Värdet representerar en kategori (t.ex. Kön, färgen på en bil, osv)

Nominaldata är kategorisk data som inte har någon naturlig ordning eller rangordning. Exempel inkluderar kön (man, kvinna), färg (röd, blå, grön) och typ av fordon (bil, cykel, buss). Går inte att beräkna medelvärde eller median, endast typvärde på nominaldata.

Ordinaldata är kategorisk data med en naturlig ordning eller rangordning, men avstånden mellan kategorierna är inte nödvändigtvis lika. Exempel inkluderar utbildningsnivå (grundskola, gymnasium, högskola) och betyg (dålig, medel, bra). Typvärde samt medianvärde kan räknas ut med ordinaldata men inte medelvärde.

Kvotdata är numerisk data med en absolut nollpunkt, vilket möjliggör meningsfulla jämförelser med både skillnader och förhållanden. Exempel inkluderar längd, vikt, ålder och inkomst.

Intervalldata är numerisk data där avstånden mellan värden är meningsfulla, men det finns ingen sann nollpunkt. Exempel inkluderar temperatur i Celsius eller Fahrenheit och årtal.

Obundet slumpmässigt urval (OSU) är en urvalsmetod där varje medlem i populationen har lika stor chans att bli vald, vilket säkerställer att urvalet är representativt för hela populationen.

Systematiskt urval är en urvalsmetod där du väljer var n:te medlem från en lista. Till exempel, om du har en lista med 100 personer och vill välja var 10:e person, börjar du med att slumpmässigt välja en startpunkt mellan 1 och 10. Därefter väljer du var 10:e person på listan (t.ex., den 10:e, 20:e, 30:e, etc.) tills du når slutet av listan.

Stratifierat urval är en urvalsmetod där populationen delas in i grupper (strata) baserat på specifika egenskaper, och slumpmässiga urval görs inom varje strata. Detta säkerställer att varje grupp är representerad i urvalet.

Klusterurval är en urvalsmetod där populationen delas in i grupper (kluster), och hela kluster väljs slumpmässigt för analys, istället för att välja enskilda medlemmar inom klustren.

Varians är ett mått på hur mycket värdena i en dataset sprider sig från medelvärdet.

Exempel: Om vi har datan 2, 4, 6, 8, 10, visar variansen hur mycket varje tal i denna data avviker från medelvärdet 6.

En **frekvensfördelning** är en tabell eller graf som visar hur ofta olika värden förekommer i en dataset. Den används för att sammanfatta data och identifiera mönster eller trender.

- **Absolut frekvens:** Antalet gånger ett värde förekommer i en dataset.

- **Relativ frekvens:** Andelen av det totala antalet observationer som ett värde utgör, ofta uttryckt i procent.

2. Sannolikhetslära

Ett experiment är ett skeende som leder till ett av flera olika möjliga utfall.

Ett utfall är resultatet av ett experiment.

En sannolikhet är ett mått på hur troligt det är att ett experiment får ett visst utfall.

Ett utfallsrum är de olika möjliga utfall som ett experiment kan leda till.

En händelse är en delmängd av ett utfallsrum.

Komplementet till en händelse är att händelsen inte inträffar.

Två händelser är endast komplement om additionen mellan båda är exakt 1.

Subtraktionsregeln: $P(c) = P(A) - 1$

Unionen mellan två händelser innebär att minst en av de båda händelserna inträffar.

Snittet mellan två händelser innebär att båda händelserna inträffar.

Disjunkta händelser är ömsesidigt uteslutande. ($P(A \cap B) = 0$)

Betingad sannolikhet är sannolikheten för att en händelse inträffar, givet att en annan händelse redan har inträffat. Den betecknas som $P(A|B)$ och läses "sannolikheten för A givet B".

Unionregeln: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

Räkneregeln för betingad sannolikhet: $P(A|B) = P(A \cap B) / P(B)$

Multiplikationsprincipen för oberoende händelser: $P(A \cap B) = P(A) * P(B)$ (endast om A och B är oberoende)

Bayes teorem:

Betingad sannolikhet räknas som: $P(A|B) = P(A \cap B) / P(B)$

Räkneregeln för betingad sannolikhet $P(A|B) = P(A \cap B) / P(B)$, som sagt kan vi utnyttja det uppenbara faktum att $P(A \cap B) = P(B \cap A)$

Vi kan då konstatera att $P(A|B) = P(A \cap B) / P(B) = P(B \cap A) / P(B)$.

Subtraktionsregeln säger att $P(B) = P(B \cap A) + P(B \cap \bar{A})$ vilket ger oss $P(A|B) = P(B \cap A) / P(B \cap A) + P(B \cap \bar{A})$

Eftersom vi ett att

$P(A \cap B) = P(A) * P(B|A) \rightarrow P(B \cap A) = P(B|A) * P(A)$ och att $P(B \cap \bar{A}) = P(B|\bar{A}) * P(\bar{A})$

Så kan vi skriva

$$P(A|B) = P(B|A) * P(A) / P(B|A) * P(A) + P(B|\bar{A}) * P(\bar{A})$$

Fakulteten för ett tal n : $n! = n(n-1)(n-2) \dots 1$

En permutation är ett möjligt sätt att välja ut och rangordna r element från en mängd bestående av n element.

Antal permutationer: $nPr = \frac{n!}{(n-r)!}$

En kombination är ett möjligt sätt att välja ut r element från en mängd bestående av n element där den inbördes ordningen mellan de r elementen inte är relevant.

Antal kombinationer: $nCr = \binom{n}{r} = \frac{n!}{r!(n-r)!}$

3. Diskreta fördelningar

En slumpvariabel X är en variabel som får sitt värde x i en process som är påverkad av slumpen

Exempel på *diskreta* slumpvariabler:

- Antalet defekta komponenter som kommer att hittas i ett stickprov om fem komponenter: Utfallsrummet är då $\{0, 1, 2, 3, 4, 5\}$.
- Antalet pojkar i en barnfamilj med ett barn. Utfallsrummet är då $\{0, 1\}$.
- Antalet pojkar i en barnfamilj med två barn. Utfallsrummet är då $\{0, 1, 2\}$.
- Antalet kunder i en viss affär en viss dag. Utfallsrummet är då $\{0, 1, 2, 3, \dots\}$.

Diskreta slumpvariabler är nästan alltid ett heltalsvärde, en annan slumpvariabel som kan anta vilket värde som helst i ett visst intervall kallas för *kontinuerlig* slumpvariabel.

Exempel på *kontinuerliga* slumpvariabler:

- Temperaturen (i grader Celsius) i en viss masugn.
- Tiden (i minuter) en kund får vänta på betjäning i en viss kassakö.
- Vikten (i gram) på vissa nyskördade äpplen.
- Diametern (i cm) på vissa kullager ringar.

En diskret slumpvariabel kan bara anta vissa värden, normalt heltalsvärden.

En kontinuerlig slumpvariabel kan anta vilket värde som helst inom ett visst intervall.

Varje diskret sannolikhetsfördelning måste uppfylla villkoret $P(X = x_i) = 1$

Slumpvariabelns *kumulativa fördelingsfunktion* $F(x) = P(X \leq x)$.

Väntevärdet för en diskret slumpvariabel X : $E(X) = \sum_{i=1}^n x_i \cdot p(x = x_i)$

Variansen för en diskret slumpvariabel X : $V(X) = \sum_{i=1}^n (x_i - E(x))^2 \cdot p(X = x_i)$

Variansen för en diskret slumpvariabel X när $P(X = x) = (1/n)$ för alla x :

$$V(X) = \sum_{i=1}^n (x_i - E(x))^2 (1/n) = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n}, \text{ då } E(X) = \mu$$

Standardavvikelsen för en diskret slumpvariabel X : $S(X) = \sqrt{V(X)}$

Väntevärdet för en funktion av en diskret slumpvariabel X :

$$E(f(X)) = \sum_{i=1}^n f(x_i) \cdot p(X = x_i)$$

Om en funktion är en *linjär* funktion av X , d.v.s om funktionen kan skrivas $f(X) = aX + b$ där a och b är konstanter, så förenklas beräkningsformeln för funktionens väntevärde väsentligt då a kan brytas ut.

Väntevärdet för en linjär funktion av en diskret slumpvariabel X : $E(aX + b) = a \cdot E(X) + b$

Variansen för en linjär funktion av en diskret slumpvariabel X : $V(aX + b) = a^2 \cdot V(X)$

En standard fördelad diskret slumpvariabel är en diskret slumpvariabel vars sannolikhetsfördelning definieras fullt ut via givna antaganden om sättet på vilket variabeln får sitt utfall.

Standardfördelningar:

- Binomialfördelningen
- Poissonfördelningen
- Hypergeometrisk fördelningen
- Geometrisk fördelningen
- Negativa binomialfördelningen

Binär slumpvariabel (Bernoulliförsök $\{0, 1\}$): $V(X) = p(1 - p)$

Väntevärdet och variansen för en binomialfördelad slumpvariabel X (där X är en binomialfördelad variabel med n försök och sannolikheten p i varje försök): Om $X \sim B(n, p)$ så blir $E(X) = n \cdot p$ och $V(X) = n \cdot p(1 - p)$

Försöken måste vara oberoende av varandra. Med detta avses att resultatet i något av Bernoulliförsöken i sekvensen inte får påverkas på något sätt av resultatet i något annat av försöken i sekvensen.

Antalet möjliga kombinationer av x enheter från en mängd n enheter beräknas med den vanliga kombinationsformeln: $\binom{n}{x} = \frac{n!}{x!(n-x)!}$ Sätt att välja ut x enheter från en mängd n enheter.

Var och en av dessa kombinationer innebär att sekvensen med Bernoulliförsök har resulterat i x stycken S och $(n-x)$ stycken $\bar{S}$. Sannolikheten för att ett enskilt Bernoulliförsök resulterar i S är p , och således måste för att ett enskilt Bernoulliförsök resulterar i $\bar{S}$ vara $(1 - p)$. Varje enskild kombination av x stycken S från sekvensen med Bernoulliförsök har då sannolikheten

$p^x(1-p)^{(n-x)}$. Genom att multiplicera denna sannolikhet med antalet sådana kombinationer får vi sannolikheten för att sekvensen med n Bernoulliförsök resulterar just i x stycken utfall av typen S .

Binomialfördelningen: Om $X \sim B(n, p)$ så blir $P(X = x) = \binom{n}{x} p^x (1 - p)^{(n-x)}$

Steg 1: Förstå problemet

Anta att vi har en binomialfördelning med n försök och en sannolikhet p för framgång vid varje försök. Vi är intresserade av sannolikheten för att få exakt x framgångar.

Steg 2: Använd binomialfördelningens formel

Binomialfördelningens formel är:

$$P(X = x) = \binom{n}{x} p^x (1 - p)^{(n-x)} \text{ där:}$$

- $P(X = x)$ är sannolikheten för att få exakt x framgångar.
- $\binom{n}{x}$ är binomialkoefficienten, som beräknas $\frac{n!}{x!(n-x)!}$.
- p är sannolikheten för framgång vid varje försök.
- $(1 - p)$ är sannolikheten för misslyckande vid varje försök.

Steg 3: Använd subtraktionsregeln (komplementregel)

Subtraktionsregeln används för att hitta sannolikheten för att en händelse inte inträffar genom att subtrahera sannolikheten för att händelsen inträffar från 1. I binomialfördelningar kan detta användas för att hitta sannolikheten för att få högst x framgångar eller minst x framgångar.

Exempel 1: Sannolikheten för att få minst x framgångar

För att hitta sannolikheten för att få minst x framgångar, använder vi:

$$P(X \geq x) = 1 - P(X < x)$$

Där $P(X < x)$ är summan av sannolikheterna för att få färre än x framgångar:

$$P(X < x) = \sum_{i=0}^{x-1} P(X = i)$$

Exempel 2: Sannolikheten för att få högst x framgångar

För att hitta sannolikheten för att få högst x framgångar, använder vi:

$$P(X \leq x) = 1 - P(X < x)$$

Där $P(X > x)$ är summan av sannolikheterna för att få fler än x framgångar:

$$P(X > x) = \sum_{i=x+1}^n P(X = i)$$

Steg 4: Beräkning

Låt oss anta att vi har en binomialfördelning med $n=10$ försök och sannolikheten för framgång $p=0.3$. Vi vill hitta sannolikheten för att få minst 3 framgångar ($X \geq 3$).

1. Beräkna sannolikheterna för färre än 3 framgångar:

$$P(X < 3) = P(X=0) + P(X=1) + P(X=2)$$

Använd binomialformeln för varje term:

$$P(X = 0) = \binom{10}{0} (0.3)^0 (0.7)^{10} = 1 \cdot 1 \cdot (0.7)^{10} \approx 0.0282$$

$$P(X = 1) = \binom{10}{1} (0.3)^1 (0.7)^9 = 10 \cdot 1 \cdot (0.7)^9 \approx 0.1211$$

$$P(X = 2) = \binom{10}{2} (0.3)^2 (0.7)^8 = 45 \cdot 1 \cdot (0.7)^8 \approx 0.2335$$

2. Summera dessa sannolikheter:

$$P(X < 3) \approx 0.0282 + 0.1211 + 0.2335 = 0.3828$$

3. Använd subtraktionsregeln:

$$P(X \geq 3) = 1 - P(X < 3) = 1 - 0.3828 = 0.6172$$

Så sannolikheten för att få minst 3 framgångar är cirka 0.6172.

Vad är Poissonfördelningen?

Poissonfördelningen är en diskret sannolikhetsfördelning som anger sannolikheten för att ett givet antal händelser inträffar inom ett fast tidsintervall eller inom ett fast område. Fördelningen används ofta för att modellera antalet händelser som sker oberoende av varandra med en konstant genomsnittlig hastighet.

Grundläggande Egenskaper

- Diskret fördelning: Poissonfördelningen gäller för heltalsvärden (0, 1, 2, ...).
- Parameter: Den har en enda parameter, μ som representerar det genomsnittliga antalet händelser inom det givna tidsintervallet eller området.
- Väntevärdet och variansen för en Poissonfördelad slumpvariabel X : Om $X \sim P(\mu)$ så blir $E(X) = n \cdot p = \mu$ och $V(X) = n \cdot p = \mu$
- Poissonfördelningen: Om $X \sim P(\mu)$ så blir

$$P(X = x) = \frac{\mu^x e^{-\mu}}{x!}$$

- Sannolikhetsmassafunktion PMF: Sannolikheten för att få exakt x händelser ges av:

$$P(X = x) = \frac{\mu^x e^{-\mu}}{x!}$$

där:

- $P(X = x)$ är sannolikheten för att få exakt x händelser.
- μ är det genomsnittliga antalet händelser per tidsenhet eller område.
- e är basen för den naturliga logaritmen (ungefär 2.71828).
- x är antalet händelser.
- $x!$ är x fakultet.

När används Poissonfördelningen?

Poissonfördelningen används när:

- Händelser inträffar oberoende av varandra.
- Händelser inträffar med en konstant genomsnittlig hastighet.
- Händelser inträffar en i taget (ingen samtidig förekomst).

Vanliga användningsområden inkluderar:

- Antalet telefonsamtal som anländer till en växel under en timme.
- Antalet bilar som passerar genom en viss punkt på en väg under en timme.
- Antalet fel som uppstår på en maskin per dag.

Exempel 1:

Anta att vi vill modellera antalet kunder som anländer till en bank per timme, och vi vet att i genomsnitt anländer 5 kunder per timme $\mu = 5$.

Exempel 1: Sannolikheten för att exakt 3 kunder anländer på en timme

Vi använder Poissonfördelningens PMF för att beräkna denna sannolikhet:

$$P(X = 3) = \frac{5^3 e^{-5}}{3!} = \frac{125 \cdot e^{-5}}{6} \approx 0.1404$$

Så sannolikheten för att exakt 3 kunder anländer på en timme är cirka 0.1404.

Exempel 2: Sannolikheten för att högst 2 kunder anländer på en timme

Vi måste summera sannolikheterna för att 0, 1 och 2 kunder anländer:

$$P(X \leq 2) = P(X = 0) + P(X = 1) + P(X = 2)$$

Där:

$$P(X = 0) = \frac{5^0 e^{-5}}{0!} = e^{-5} \approx 0.0067$$

$$P(X = 1) = \frac{5^1 e^{-5}}{1!} = 5e^{-5} \approx 0.0337$$

$$P(X = 2) = \frac{5^2 e^{-5}}{2!} = \frac{25e^{-5}}{2} \approx 0.0842$$

Summera dessa:

$$P(X \leq 2) \approx 0.0067 + 0.0337 + 0.0842 = 0.1246$$

Så sannolikheten för att högst 2 kunder anländer på en timme är cirka 0.1246.

Sammanfattning

Poissonfördelningen är en kraftfull modell för att analysera antalet händelser inom ett fast tidsintervall eller område, särskilt när dessa händelser är oberoende och inträffar med en konstant genomsnittlig hastighet. Den enkla formeln och de tydliga användningsområdena gör den till ett viktigt verktyg inom sannolikhetsteori och statistiken.

Minst: $\leq$

Högst: $1 - \geq$ (en siffra lägre)

4. Kontinuerliga fördelningar

En likformig fördelning kännetecknas av att dess sannolikhetskurva är rektangulär.

Exponentialfördelningen: $X \sim EXP(\mu)$ så blir $P(X > x) = e^{\frac{-x}{\mu}}$

När $X < x$ så blir $1 - \text{exponentialfördelningen}$

Sannolikhetskurvan $f(x)$ för en normalfördelning med medelvärde μ och standardavvikelsen

σ definieras formellt av $f(x) = \frac{e^{-0,5\left(\frac{x-\mu}{\sigma}\right)^2}}{\sigma\sqrt{2\pi}}$ parametrarna i denna formel är μ och σ ,

betecknas med $X \sim N(\mu, \sigma)$

Additivitet: Om slumpvariablerna $X_1, X_2, \dots, X_n$ är oberoende och normalfördelade och $S = X_1 + X_2 \dots + X_n$ så är S en normalfördelad slumpvariabel med

$$\begin{aligned} E(S) &= E(X_1) + E(X_2) \dots + E(X_n) \\ V(S) &= V(X_1) + V(X_2) \dots + V(X_n) \\ S(S) &= \sqrt{V(X_1) + V(X_2) \dots + V(X_n)} \end{aligned}$$

I de allra enklaste fallet kommer samtliga n slumpvariabler $X_1 + X_2 \dots + X_n$ från samma normalfördelning $X \sim N(\mu, \sigma)$. I så fall är $E(X) = E(X_1) + E(X_2) \dots + E(X_n) = \mu$ och $V(X) = V(X_1) + V(X_2) \dots + V(X_n) = \sigma^2$, vilket innebär att väntevärdet variansen och standardavvikelsen för variabelsumman $S = \sum x_i$ med hjälp av additiviteten förenklas till:

$$\begin{aligned} E(\sum x_i) &= n \cdot \mu \\ V(\sum x_i) &= n \cdot \sigma^2 \\ &\text{och} \\ S(\sum x_i) &= \sqrt{n \cdot \sigma^2} = \sigma \cdot \sqrt{n} \end{aligned}$$

Ovanstående förenklade uttryck för en variabelsummas väntevärde, varians och standardavvikelse är av stor vikt vid stickprovsanalys, eftersom ett stickprovsmedelvärde är just summan av ett antal slumpvariabler som kommer från samma fördelning.

Den standardnormalfördelade slumpvariabeln Z har medelvärdet 0 och standardavvikelsen 1. Dvs. $Z \sim N(0,1)$.

För att beräkna sannolikheten $P(-1 < Z < 1,5)$ där Z är en standardnormalfördelad variabel (dvs. $Z \sim N(0,1)$), använde man standardnormalfördelningens kumulativa fördelningsfunktion (CDF), som ofta betecknas med $\Phi(z)$.

1. Sannolikhetens definition:

$$P(-1 < Z < 1,5) = \Phi(1,5) - \Phi(-1)$$

2. Hitta värdena för CDF:

- $\Phi(1,5)$ är sannolikheten att Z är mindre än eller lika med 1,5.
- $\Phi(-1)$ är sannolikheten att Z är mindre än eller lika med -1 .

Dessa värden kan man antingen slå upp i en standardnormalfördelningstabell eller använda en räknare eller mjukvara som kan beräkna dem.

3. Beräkna värdena:

- $\Phi(1,5) \approx 0,9332$ för att $\Phi(1,5) \approx 0,0668$ och $\Phi(1,5) \approx 1 - 0,0668 = 0,9332$
-
- $\Phi(-1) \approx 0,1587$ för att $\Phi(1) \approx 0,841$ och $\Phi(-1) \approx 1 - 0,8413 = 0,1587$

4. Subtrahera de två sannolikheterna:

$$P(-1 < Z < 1.5) = 0.9332 - 0.1587 = 0.7745$$

Transformation av X till Z : $Z = \frac{X-\mu}{\sigma}$

T.ex: $P(X > 9)$ när $X \sim N(7, 2)$. När vi transformerar detta problem från X till Z får vi således

$$P(X > 9) = P\left(\frac{X-\mu}{\sigma} > \frac{9-\mu}{\sigma}\right) = P\left(Z > \frac{9-7}{2}\right) = P(Z > 1) = 0.1587$$

$X \sim N(\mu, \sigma)$, μ är medelvärde, σ är standardavvikelsen

$x = \mu + z \cdot \sigma$, t.ex. $P(X > 23,08)$ när $X \sim N(20, 4)$ är $P(Z > 0,77)$ för att

$$P(X > 23,08) = P\left(\frac{x-\mu}{\sigma} > \frac{23,08-20}{4}\right) = P(Z > 0,77) = 0,2208$$

Binomialfördelningen approximerad med normalfördelningen: Om $n \cdot p \geq 5$ och $n(1-p) \geq 5$ så gäller det att $X \sim B(n, p) \approx X \sim N(n \cdot p, \sqrt{n \cdot p(1-p)})$

Kontinuitetskorrigering är en justering ($\pm 0,5$) för att förbättra approximationer av diskreta data med en kontinuerlig fördelning. T.ex. får då det diskreta värdet **87** det kontinuerliga intervallet $[86,5, 87,5]$. Ett värde som ligger i intervallet $[550, 580]$ när en normalfördelningsapproximation ska användas så innebär kontinuitetskorrigeringen att man uttrycker denna sannolikhet $P(549,5 < X < 580,5)$.

Till exempel 4.7, Sture ska kasta en tärning 3000 gånger.

- a) Vad är sannolikheten att han får minst 530 sexor?
- b) Vad är sannolikheten att han får minst 475 men högst 510 sexor?

Sannolikheten för en sexa i ett enskilt kast är $1/6 = 0,1667$. Om vi låter X beteckna antalet sexor så vet vi att $X \sim B(3000, 0,1667)$ där vi får $E(X) = 3000 \cdot$

$0.1667 = 500$ (vilket är n) och $\sigma = \sqrt{3000 \cdot 0.1667 \cdot 0.8333} = 20,4124$.

Tumregelmässigt får vi approximera X med normalfördelning eftersom $n \cdot p = 3000 \cdot 0.1667 \geq 5$ och $n \cdot (1 - p) = 3000(1 - 0.1667) \geq 5$. Vi kan alltså räkna med $X \sim N(500, 20.4124)$.

- a) $P(X \geq 530)$ måste kontinuitetskorrigeras till $P(X \geq 529,5)$ när normalfördelningen ska användas. Vi transformerar till standardnormalfördelningen: $P(X > 529,5) = P\left(Z > \frac{529,5 - 500}{20,4124}\right) = P(Z > 1,45)$

Från normalfördelningstabellen i appendix A3 får vi att $P(Z > 1,45) = 0,0735$. Sannolikheten att Sture får minst 530 sexor om han kastar tärning 3000 gånger är alltså 0,0735.

- b) Vi måste kontinuitetskorrigera $P(475 \leq X \leq 510)$ till $P(474,5 \leq X \leq 510,5)$ för att vi ska kunna använda normalfördelningsapproximationen. Transformation till Z ger: $P(474,5 < X < 510,5) = P\left(\frac{474,5 - 500}{20,4124} < Z < \frac{510,5 - 500}{20,4124}\right) = P(1,25 < Z < 0,51)$. Med hjälp av normalfördelningstabellen finner vi att $P(Z < -1,25) = P(Z > 1,25) = 0,1056$ och att $P(Z > -0,51) = 0,3050$. Således blir $P(-1,25 < Z < 0,51) = 1 - 0,1056 - 0,3050 = 0,5894$. Sannolikheten att Sture får minst 475 men högst 510 sexor vid 3000 tärningskast är alltså 0,5894.

Poissonfördelningen approximerad med normalfördelningen:

Om $\mu \geq 10$ så gäller det att $X \sim P(\mu) \approx X \sim N(\mu, \sqrt{\mu})$

Regler för när du subtraherar med 1:

1. Om $P(Z > z)$ (z-värdet är positivt):
 - Du behöver inte subtrahera med 1

$P(Z > z)$ är redan korrekt direkt från tabellen

Regler för $P(Z < z)$:

1. Om $P(Z < z)$ (z-värdet är positivt):
 - Du behöver subtrahera med 1:
2. Om $P(Z < z)$ (z-värdet är negativt):
 - Du behöver subtrahera med 1:

5. Stickprovsfördelningar

En statistika är ett kvantitativt mått eller värde som beskriver ett stickprov.

En väntevärdesriktig skattning innebär att skattningens förväntade värde är lika med sanna värdet för den populationsparameter som skattas.

Standardavvikelsen för $\bar{X}$ är $S(\bar{X}) = \frac{\sigma \cdot \sqrt{n}}{n} = \frac{\sigma}{\sqrt{n}}$, som kallas för skattningens medelfel.

Väntevärde och medelfel för $\bar{X}$ vid stickprov med storleken n från en normalfördelad population.

Om $X \sim N(\mu, \sigma)$ så gäller att

Väntevärdet: $E(\bar{X}) = \mu$

Medelfelet: $S(\bar{X}) = \frac{\sigma}{\sqrt{n}}$

Om $X \sim N(\mu, \sigma)$ så gäller att $\bar{X} \sim N(\mu, \frac{\sigma}{\sqrt{n}})$

Centrala gränsvärdessatsen: För en godtyckligt fördelad slumpvariabel X med medelvärdet μ och standardavvikelsen σ så gäller om n är stort att

- slumpvariabeln $\bar{X}$ kommer att vara normalfördelad
- $E(\bar{X}) = \mu$
- $S(\bar{X}) = \frac{\sigma}{\sqrt{n}}$

Ett stickprovsmedelvärde $\bar{X}$ får antas vara en normalfördelad slumpvariabel med medelvärdet μ och standardavvikelsen ("medelfelet") $\frac{\sigma}{\sqrt{n}}$ om ett av två villkor är uppfyllt:

- Stickprovet är taget från en normalfördelad population
- Stickprovet är stort ($n \geq 30$)

När ett stickprov kommer från en population som åtminstone approximativt är en normalfördelning så kommer statistikan $(\bar{X} - \mu) / (s / \sqrt{n})$ att följa t -fördelningen med $n - 1$ frihetsgrader oavsett storleken på stickprovet.

Om det samtidigt kan antas gälla att $n \cdot p \geq 5$ och $n(1 - p) \geq 5$ så gäller för stickprovsproportionen $\hat{p} = X / n$ approximativt att $\hat{p} \sim N(p, \sqrt{p(1 - p) / n})$

6. Konfidensintervall

Ett konfidensintervall är ett intervall som antas innehålla en okänd populationsparameter. Till varje konfidensintervall hör ett mått på den säkerhet – konfidens – med vilken intervallet faktiskt innehåller populationsparametern i fråga.

Ett 95% konfidensintervall för μ när σ är känd och stickprovstagningen sker från en normalfördelad population eller när stickprovssorleken n är stor: $\bar{x} \pm 1.96(\sigma / \sqrt{n})$

Ett $1 - \alpha$ konfidensintervall för μ när σ är känd och stickprovstagningen sker från en normalfördelad population eller när stickprovsstorleken n är stor: $\bar{x} \pm Z_{\alpha/2}(\sigma / \sqrt{n})$ där $\alpha / 2$ är den återstående ytan under högra svansen i Z -fördelningen bortom värdet $Z_{\alpha/2}$.

Allt annat lika innebär vart och ett av följande tre fenomen ett bredare konfidensintervall:

- Högre konfidensnivå
- Större standardavvikelse
- Mindre stickprovsstorlek

Ett $1 - \alpha$ konfidensintervall för μ när σ är okänd men skattad av S och stickprovstagningen sker från en normalfördelad population: $\bar{x} \pm t_{\alpha/2}(s / \sqrt{n})$ där n är stickprovsstorleken och $\alpha / 2$ är den återstående ytan under högra svansen i t -fördelningen bortom värdet $t_{\alpha/2}$ med $n - 1$ frihetsgrader.

Ett $1 - \alpha$ konfidensintervall för p när $n \cdot \hat{p} \geq 5$ och $n(1 - \hat{p}) \geq 5$:

$\hat{p} \pm Z_{\alpha/2}\sqrt{\hat{p}(1 - \hat{p}) / (n - 1)}$ där $\alpha / 2$ är den återstående ytan under högra svansen i Z -fördelningen bortom värdet $Z_{\alpha/2}$.

Ett $1 - \alpha$ konfidensintervall för μ när σ är känd och stickprovstagningen sker från en population av storleken N och $\bar{x}$ får antas vara normalfördelad:

$\bar{x} \pm Z_{\alpha/2} \sqrt{(N - n) / N} \cdot \sigma / \sqrt{n}$ där n är stickprovsstorleken och $\alpha / 2$ är den återstående ytan under högra svansen i Z -fördelningen bortom värdet $Z_{\alpha/2}$.

Ett $1 - \alpha$ konfidensintervall för μ när σ är okänd men skattad av S och stickprovstagningen sker från en normalfördelad population av storleken N : $\bar{x} \pm t_{\alpha/2} \sqrt{(N - n) / N} \cdot s / \sqrt{n}$ där n är stickprovsstorleken och $\alpha / 2$ är den återstående ytan under högra svansen i t -fördelningen bortom värdet $t_{\alpha/2}$ med $n - 1$ frihetsgrader.

Ett $1 - \alpha$ konfidensintervall för p när $n \cdot \hat{p} \geq 5$ och $n(1 - \hat{p}) \geq 5$:

$\hat{p} \pm Z_{\alpha/2} \sqrt{(N - n) / N} \cdot \sqrt{\hat{p}(1 - \hat{p}) / (n - 1)}$ där n är stickprovsstorleken och $\alpha / 2$ är den återstående ytan under högra svansen i Z -fördelningen bortom värdet $Z_{\alpha/2}$.

Minsta möjliga stickprovsstorlek för att skatta det sanna populationsmedelvärdet μ :

$$n = (Z_{\alpha/2} \sigma / B)^2$$

Minsta möjliga stickprovsstorlek för att skatta den sanna populationsproportionen p :

$$n = (Z_{\alpha/2} \sqrt{p(1 - p)} / B)^2$$

7. Test av hypoteser

Ett hypotestest är ett test av en populationsparameters värde. Testet baseras på en nollhypotes (H_0) och en mothypotes (H_1) som är nollhypotesens komplement. Om man via stickprov får tillräckligt starka bevis mot H_0 förkastas H_0 , vilket innebär att hypotestest resulterar i slutsatsen att H_1 är sann.

Alternativet med likhet kan bara förekomma i en nollhypotes. Det finns därför tre olika former av enkla hypotestester:

- Tvåsidigt (skild från) test, t.ex. $H_0: \mu = 20$ och $H_1: \mu \neq 20$
- Ensidigt (mindre än) test, t.ex. $H_0: \mu \geq 20$ och $H_1: \mu < 20$
- Ensidigt (större än) test, t.ex. $H_0: \mu \leq 20$ och $H_1: \mu > 20$

Ett p-värde är sannolikheten att av en slump få stickprovsdata som talar mot H_0 minst lika mycket som de stickprovsdata vi faktiskt fick givet att H_0 är sann.

Beslutsregel vid hypotestestning: Om p-värdet är lägre än signifikansnivån α så förkastas H_0 .

Gången i ett hypotestest:

1. Formulera hypoteser som överensstämmer med problemet
2. Bestäm α
3. Samla in stickprovsdata
4. Gör beräkningar med hjälp av stickprovsdatan
5. Dra slutsatsen att H_1 är sann om p-värdet understiger α

Ett hypotestest kan genomföras på två olika sätt:

- Beräkna ett p-värde för testet och jämför med α . Om p-värdet är lägre än α ska H_0 förkastas.
- Beräkna värdet för en testvariabel och jämför testets kritiska område. Om testvärdet ligger i testets kritiska område ska H_0 förkastas.

Testvariabel för hypotestest av populationsmedelvärde om populationen är approximativt normalfördelad:

$$t = \frac{(\bar{x} - \mu_0)}{(s / \sqrt{n})}$$

där kritiskt t baseras på $n - 1$ frihetsgrader.

Det kritiska området i ett hypotestest:

- a) För $H_0: \mu \leq \mu_0$ utgörs kritiska området av högra svansen.
- b) För $H_0: \mu \geq \mu_0$ utgörs kritiska området av vänstra svansen.
- c) För $H_0: \mu = \mu_0$ utgörs kritiska området av båda svansarna.

Teststatistiska för hypotestest av populationsparametern baserat på stort stickprov:

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$$

När det står minst använd $H_0 \leq$, när det står högst använd $\geq$

Om testvärdet överstiger det kritiska värdet eller om p-värdet är mindre än signifikansnivån, förkastar man nollhypotesen.

8. Jämförelse av två populationer

Ett $1 - \alpha$ konfidensintervall för $p_1 - p_2$ för stora stickprov:

$$(\hat{p}_1 - \hat{p}_2) \pm Z_{\alpha/2} \sqrt{\hat{p}_1(1 - \hat{p}_1) / (n_1 - 1) + \hat{p}_2(1 - \hat{p}_2) / (n_2 - 1)}$$

Testvariabel för hypotestest av skillnad mellan två populationsproportioner baserat på stora stickprov när populationsproportionerna antas vara olika i H_0 :

$$Z = \frac{(\hat{p}_1 - \hat{p}_2) - D}{\sqrt{\hat{p}_1(1 - \hat{p}_1) / (n_1 - 1) + \hat{p}_2(1 - \hat{p}_2) / (n_2 - 1)}}$$

Testvariabel för hypotestest av skillnad mellan två populationsproportioner baserat på stora stickprov när populationsproportionerna antas vara lika i H_0 :

$$Z = \frac{\hat{p}_1 - \hat{p}_2}{\hat{p}(1 - \hat{p})(1 / n_1 + 1 / n_2)}$$

Testvariabel för hypotestest av differens mellan populationsmedelvärden om populationerna är approximativt normalfördelade med standardavvikelser som kan vara olika:

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - D}{\sqrt{s_1^2 / n_1 + s_2^2 / n_2}}$$

där antalet frihetsgrader som kritiskt t baseras på approximeras som

$$fg = \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{(s_1^2/n_1)^2/(n_1-1) + (s_2^2/n_2)^2/(n_2-1)}$$

Ett $1 - \alpha$ konfidensintervall för $\mu_1 - \mu_2$ för normalfördelade populationer med standardavvikelser som kan vara olika:

$$(\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2} \sqrt{s_1^2 / n_1 + s_2^2 / n_2}$$

där antalet frihetsgrader approximeras som

$$fg = \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{(s_1^2/n_1)^2/(n_1-1) + (s_2^2/n_2)^2/(n_2-1)}$$

Testvariabel för hypotestest av differens mellan populationsmedelvärden om populationerna är approximativt normalfördelade med standardavvikelser som antas vara lika:

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - D}{s_p \sqrt{(1/n_1 + 1/n_2)}}$$

med $n_1 + n_2 - 2$ frihetsgrader och där

$$s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$$

Ett $1 - \alpha$ konfidensintervall för $\mu_1 - \mu_2$ för normalfördelade populationer med lika standardavvikelser:

$$(\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2} s_p \sqrt{(1/n_1 + 1/n_2)}$$

med $n_1 + n_2 - 2$ frihetsgrader och där

$$s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$$

Testvariabel för hypotestest av differens mellan populationsmedelvärden för n parvisa observationer när de parvisa differenserna är normalfördelade:

$$t = \frac{\bar{d} - D}{s_d / \sqrt{n}}$$

där kritiskt t baseras på $n - 1$ frihetsgrader.

Ett $1 - \alpha$ konfidensintervall för $\mu_1 - \mu_2$ för n parvisa observationer när de parvisa differenserna är normalfördelade:

$$\bar{d} \pm t_{\alpha/2}(s_d / \sqrt{n})$$

med $n - 1$ frihetsgrader.